

MODÉLISATION ET RECONSTRUCTION DU TRAFIC ROUTIER

Charles PRÉVOTEAU - Erwann COGNET - Bastien COLLEAU - Paul LEHAUT

École nationale des ponts et chaussées / IP PARIS • Projet de département IMI - 2025-2026
Sous la direction de Nail BALOUL

I. Modélisation du trafic

1. Introduction

L'étude du trafic routier constitue un enjeu majeur de développement durable et de bien être en ville. L'objet de notre étude est de présenter des modèles de prédiction de l'évolution du trafic et de sa reconstruction à partir d'un nombre limité d'observations.

L'étude modélise le trafic sur une route à voie unique, selon deux niveaux de modélisation :
Modèle Microscopique : décrit le comportement individuel de chaque véhicule.
Modèle Macroscopique : assimile le flux de véhicules à l'écoulement d'un fluide.

3. Modèle macroscopique

Dans ce modèle, le flux des voitures est assimilé à l'écoulement d'un fluide, qui est décrit par le débit $q(x, t)$ (qui correspond au nombre de véhicule passant par x par unité de temps), la densité du trafic $\rho(x, t)$ et la vitesse du flux $v_{\text{flux}}(x, t)$. Ces trois grandeurs sont liées par l'équation : $q = \rho v$. La conservation du flux permet également d'établir que :

$$\frac{\partial \rho}{\partial t} + \frac{\partial q}{\partial x} = 0.$$

Pour obtenir une description complète du flux, on se place dans le cadre du modèle LW :

$$v_{\text{flux}}(x, t) = v(\rho) = v_{\max} \left(1 - \frac{\rho}{\rho_{\max}} \right)$$

et on obtient ainsi une cohérence entre les deux modèles.

2. Modèle microscopique

Dans ce modèle, le comportement d'un véhicule i est décrit par sa position $x_i(t)$ et sa vitesse $v_i(t)$. Le véhicule i suit le véhicule $i + 1$ (modèle *Follow the Leader*, noté FtL. Le premier véhicule roule à la vitesse maximale $v_{\max}$. Tous les véhicules ont la même taille ℓ et sont soumis à la même fonction de vitesse de Greenshield :

$$v : \begin{aligned} [0, \rho_{\max}] &\longrightarrow [0, v_{\max}] \\ \rho &\longmapsto v_{\max} \times \left(1 - \frac{\rho}{\rho_{\max}} \right). \end{aligned}$$

On modélise alors l'évolution du trafic de la façon suivante :

$$\begin{cases} v_N(t) = v_{\max} & \forall t \in [0, T], \\ v_i(t) = v \left(\frac{\ell}{x_{i+1}(t) - x_i(t)} \right) & \forall t \in [0, T], \forall i \in [1, N-1]. \end{cases}$$

Sous ces hypothèses, on peut montrer que les véhicules ne se percutent pas.

4. Etude numérique de convergence

Densité constante par morceaux à partir des positions déterminées par le modèle discret :

$$\rho^N(x, t) = \sum_{i=0}^{N-1} \rho_i^N(t) \mathbf{1}_{x \in [x_i(t), x_{i+1}(t))} \quad \text{avec} \quad \rho_i^N(t) = \frac{\ell}{x_{i+1}(t) - x_i(t)}, \quad i \in [0, N-1]. \quad (1)$$

On note, par ailleurs, ρ^* la densité calculée à partir du modèle continu.

On va alors observer que : $\rho^N \longrightarrow_{N \rightarrow \infty} \rho^*$ dans le sens des distances L_1 et L_2 .

5. Illustrations numériques







Fig. 1: Illustrations numériques et résultats de simulations

II. Reconstruction du trafic

6. Introduction à la reconstruction

L'objectif de cette partie est de reconstruire l'ensemble du trafic routier à partir d'un échantillon réduit de véhicules sondes. La motivation de cette approche provient notamment de l'utilisation massive mais partielle des applications d'aide à la navigation (Waze, Maps) par les automobilistes. Posons les éléments de cette reconstruction :

— **Position des véhicules sondes** : On observe $n = pN$ véhicules sondes, de positions :

$$(\bar{x}_i(t))_{t \in [0, T]}, \quad \forall i \in [0, n-1]$$

— **Reconstruction de la densité** : On définit α_i le nombre de véhicules entre le véhicule sonde i et le véhicule sonde $i + 1$. On reconstruit une densité de type piecewise :

$$\rho^N(x, t) = \sum_{i=0}^{n-1} \rho_i^N(t) \mathbf{1}_{x \in [x_i(t), x_{i+1}(t))} \quad \text{avec} \quad \rho_i^N(t) = \frac{\alpha_i \ell}{N(x_{i+1}(t) - x_i(t))}.$$

7. Réseaux de Neurones Résiduels (ResNet)

Dans cette approche, on cherche à optimiser la MSE entre les trajectoires réelles et les trajectoires prédites à partir de la densité reconstruite $\rho_{i,N}(t)$. Le respect de la physique est imposé par les contraintes.

$$\begin{aligned} \min_{\alpha} \quad & \mathcal{L}(\alpha) = \frac{1}{n} \sum_{i=1}^n |x_i(t) - \bar{x}_i(t)|^2 \\ \text{s.c.} \quad & x_i(0) = \bar{x}_i(0), \quad \forall i \end{aligned}$$

$$\alpha \in [1; z_i] \quad \text{avec} \quad z_i := \min \left(\frac{N(\bar{x}_{i+1}(0) - \bar{x}_i(0))}{L}, \frac{N(\bar{x}_{i+1}(T) - \bar{x}_i(T))}{L} \right)$$

$$x_i(t + \Delta t) = x_i(t) + v(\rho_i(t)) \Delta t, \quad \forall t, \forall i$$

$$\sum_{i=0}^{n-1} \alpha_i = N$$

L'intégration temporelle de la position est faite au sein d'une architecture ResNet.

8. Réseaux de Neurones Physiquement Informés

Les réseaux de Neurones Physiquement Informés, noté PINNs, sont des réseaux de neurones entraînés pour coïncider avec des data (les trajectoires des n véhicules sondes dans notre étude) et pour respecter des lois physiques données (modèle LW, flux de Greenshields).

La qualité du PINN se mesure à l'entraînement en combinant les loss data et physique :

$$l = \mu \cdot l_{\text{phys}} + (1 - \mu) \cdot l_{\text{data}}$$
$$l = \mu \cdot \frac{1}{N_c} \sum_{i=1}^{N_c} \left(\frac{\partial \rho_i}{\partial t} + v_{\max}(1 - 2\rho_i) \frac{\partial \rho_i}{\partial x} - \gamma \frac{\partial^2 \rho_i}{\partial x^2} \right)^2 + (1 - \mu) \cdot \frac{1}{pN} \sum_{i=0}^{pN} (\rho_{\text{pred}} - \rho_{\text{data}})^2$$

L'efficacité du PINN se mesure à l'inférence par l'Erreur d'Estimation Actuelle, notée CEE, différence entre densités reconstruite et réelle pour les $(1 - p)N$ véhicules non sondes :

$$CEE = \frac{1}{(1 - p)N} \sum_{i=0}^{(1-p)N} (\rho_{\text{test_pred}} - \rho_{\text{test}})^2$$

Dans l_{data} , nous avons fait quelque chose de nouveau pour un PINN : l'assignation aux véhicules sondes de poids d'apprentissage proportionnels à une puissance de la densité de véhicules sondes qui traduit indirectement la densité de véhicules.

9. Résultats de la reconstruction

Méthode	CEE	Entraînement	Inférence
ResNet	0.915376	338.2 s	0.1069 s
ResNet poids adaptatifs	1.037395	340.0 s	0.1655 s
PINNs	0.010712	94.1 s	0.0027 s
PINNs poids adaptatifs	0.009349	94.6 s	0.0027 s

Hyperparamètres : p = 0,2, N = 1000, epochs = 1000, optimizer = Adam, LR = 0.5

10. Et ensuite ?

Pour enrichir la critique de nos modélisations, nous aimerions comparer les résultats avec des données réelles. La rareté des données qui concordent avec notre modèle montre ses limites : la plupart des bases de données sont réalisées sur des gros axes routiers à plusieurs voies et avec des entrées et sorties, ce qui rend possible les dépassement et complique le suivi individuel des véhicules. Par ailleurs le modèle de vitesse de Greenshields est assez réducteur par rapport à la complexité du comportement des automobiles.